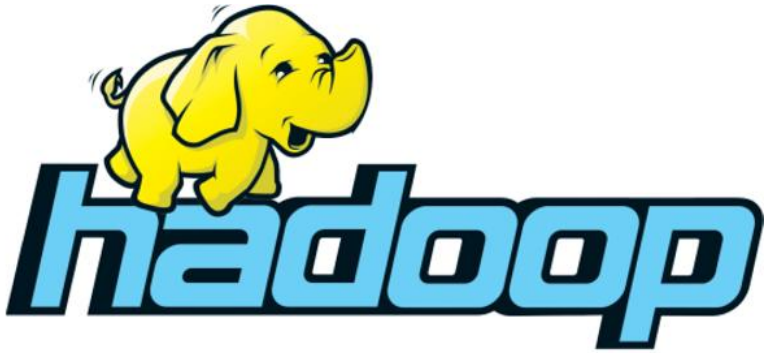

FIAP

Ecossistema Hadoop

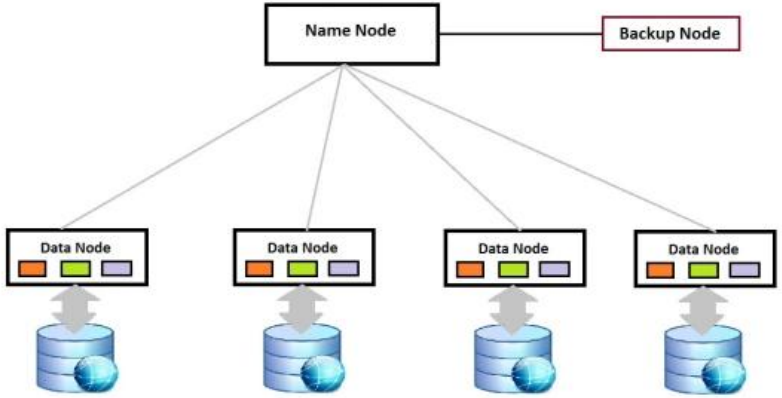
O que é Apache Hadoop?



- Apache Hadoop, é o principal **framework** utilizado para o processamento e armazenamento de grandes conjuntos de dados – *Big Data*.

O que é Apache Hadoop?

- Inicialmente inspirado no **MapReduce** e no **GoogleFS**, o Apache Hadoop é um software **Open-Source**, construído em **Java** e mantido pela Apache Foundation.





- Uma plataforma capaz de armazenar e **processar**, em **larga escala**, grandes conjuntos de dados – **Big Data**, que funciona em clusters de hardware de baixo custo, tolerante a falhas.

O que é Apache Hadoop?

- **MapReduce** é um **modelo de programação** que permite o **processamento de grandes volumes de dados**, dividindo o trabalho de processamento em um **conjunto de tarefas independentes** que são realizadas em **ambiente distribuído** e executadas de forma **paralela**.

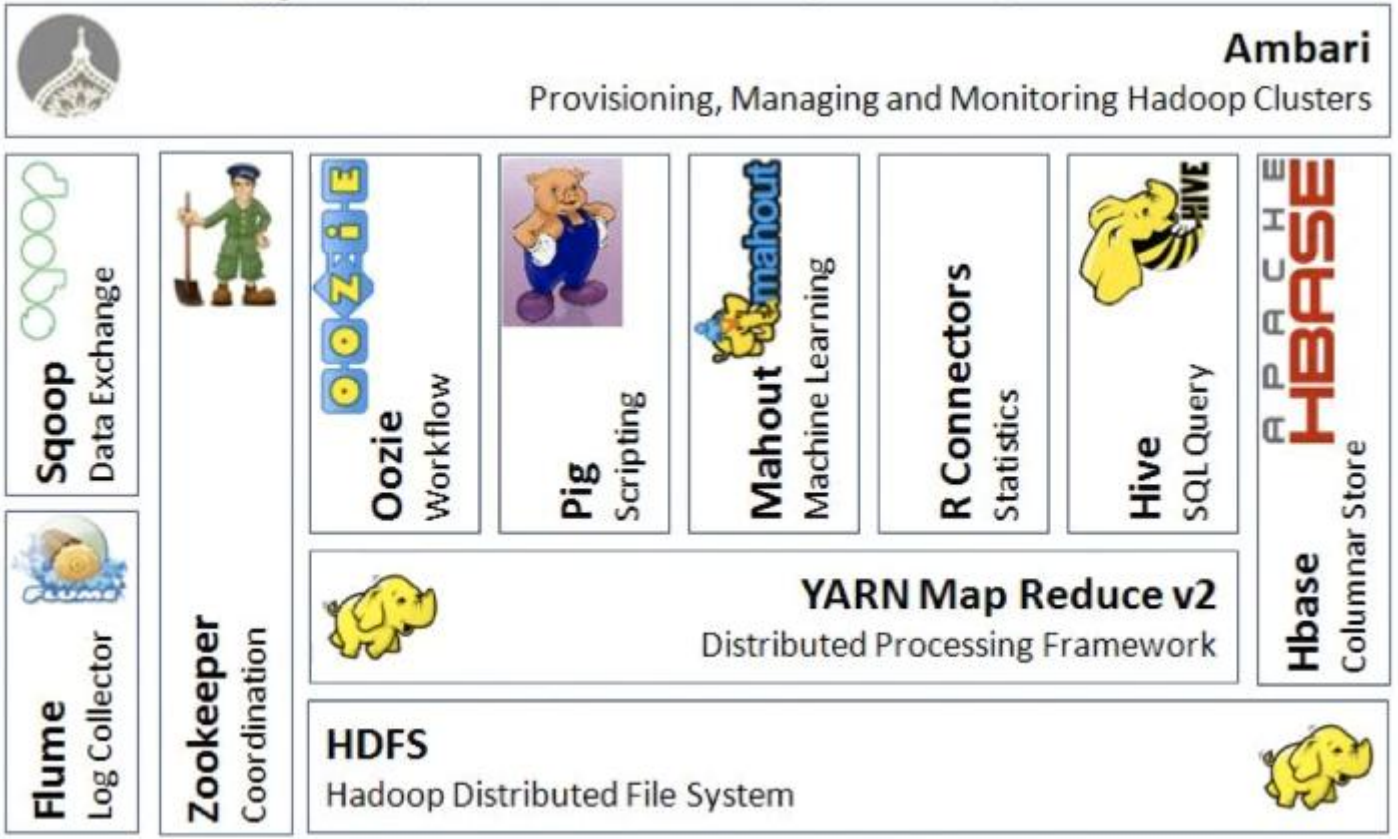


Baixo custo

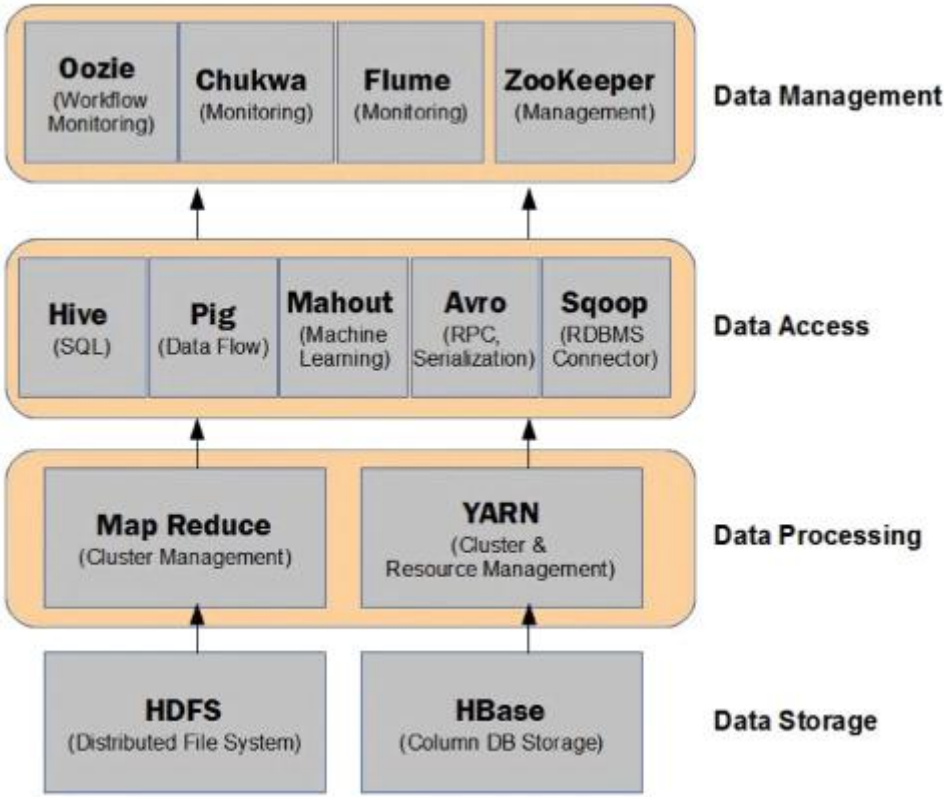


- O Hadoop Distributed File System (HDFS) é um sistema de arquivos distribuído projetado para ser executado em hardware baseado em padrões abertos ou o que é chamado de hardware commodity.
- Isso significa que o sistema é capaz de executar diferentes sistemas operacionais (SO), como Windows ou Linux, sem a necessidade de drivers especiais.

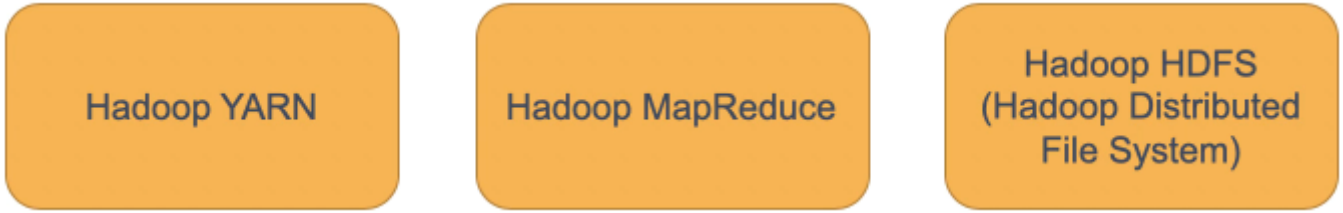
Ecossistema Apache Hadoop



Ecossistema Apache Hadoop



Projetos Principais do Ecossitema Hadoop



Outros Projetos Importantes









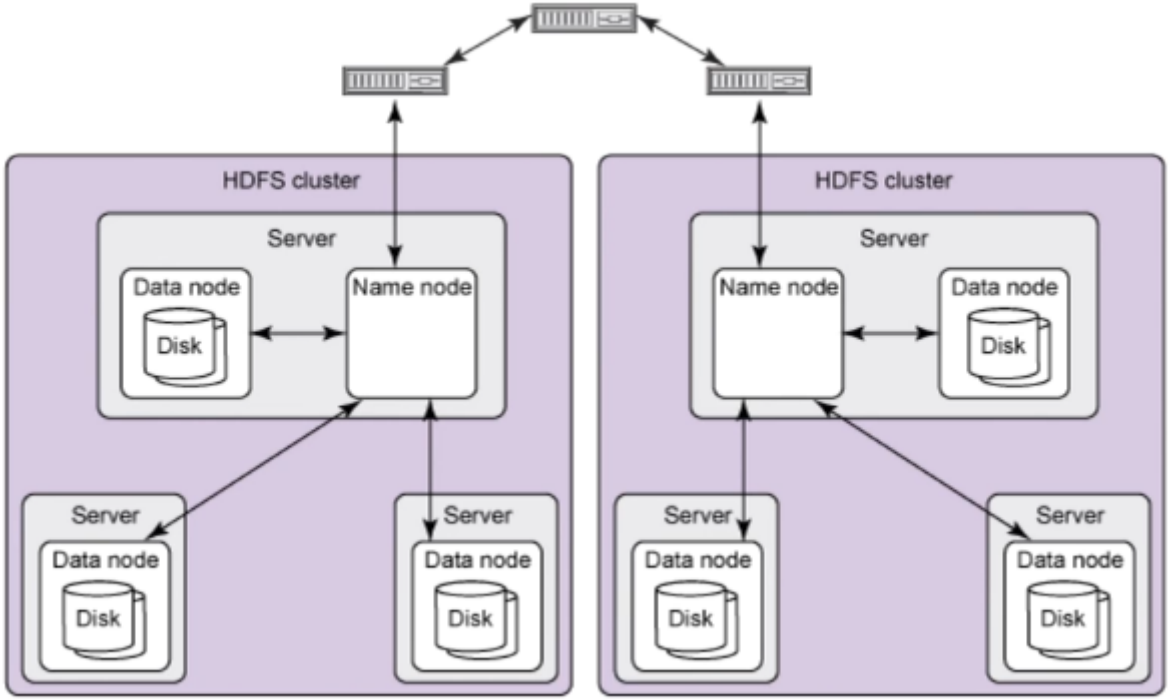






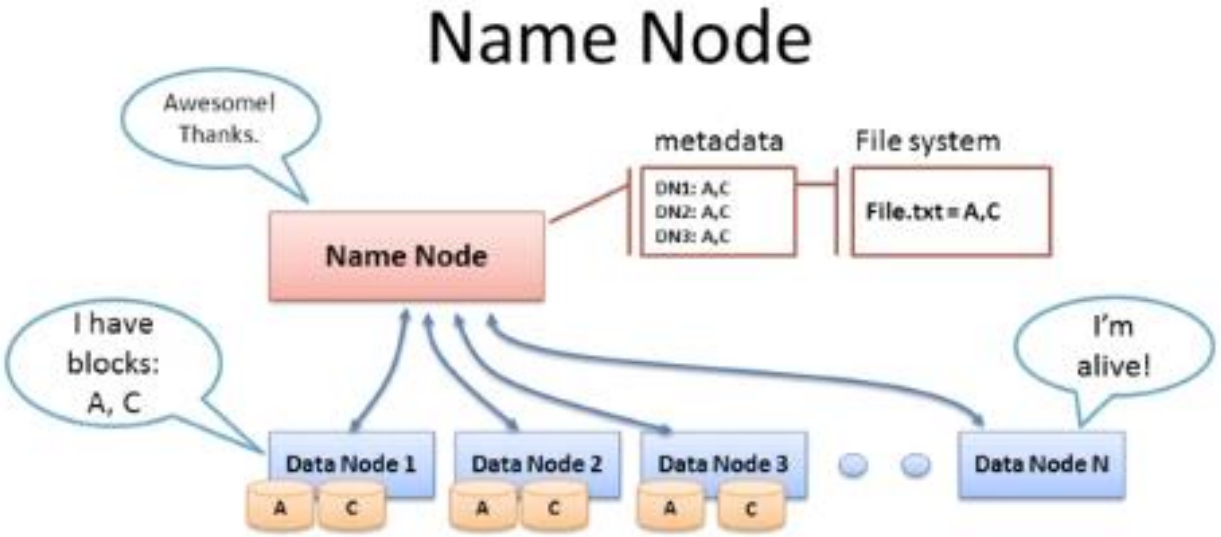


Arquitetura HDFS



Arquitetura Master/Worker

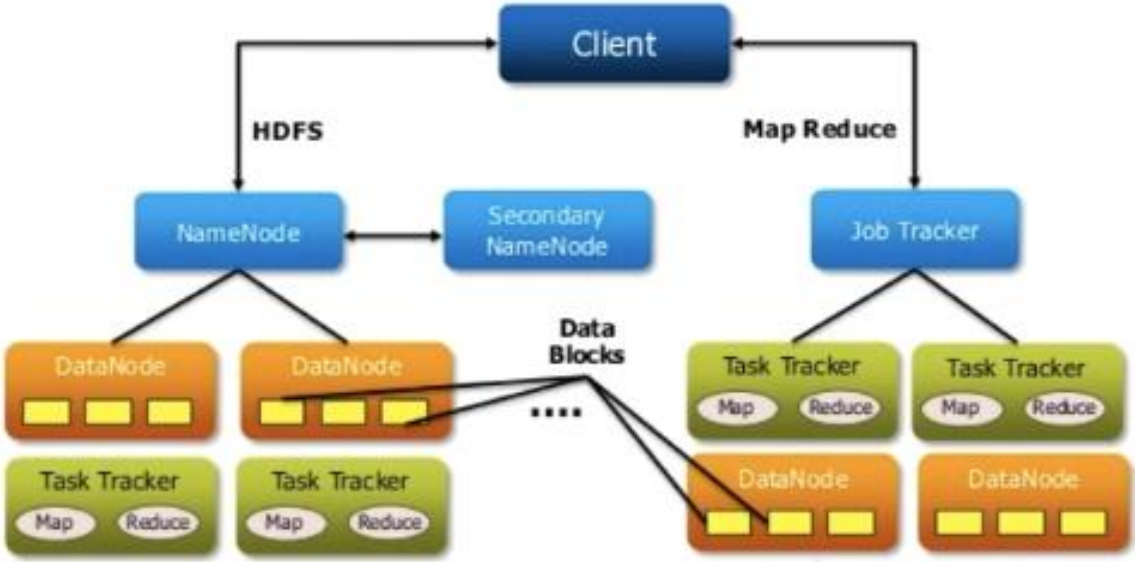
Arquitetura HDFS



NameNode

- FsImage
- EditLog

Arquitetura HDFS



NameNode

- FsImage
- EditLog

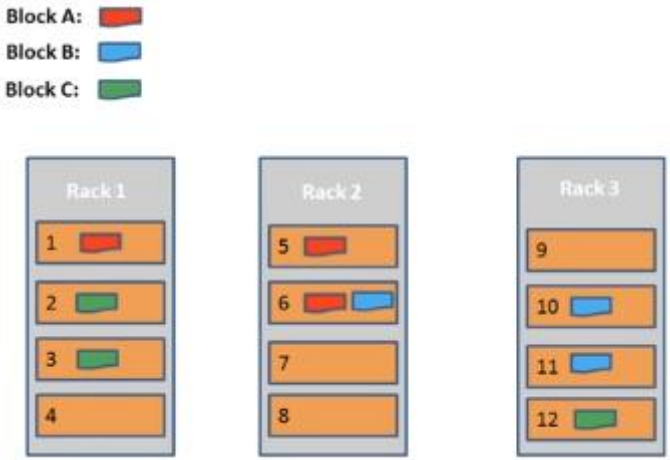
Arquitetura HDFS

Replicação



Arquitetura HDFS

Replicação



Características

- Algumas das razões para utilizar o Hadoop é a sua capacidade de armazenar, gerenciar e analisar grandes quantidades de dados estruturados e não-estruturados de forma rápida, confiável, flexível e de baixo custo.
  - Custo Baixo.
  - Escalável.
  - Flexível.
  - Open-Source.
  - Tolerante a falhas.

Confiabilidade

- Clusters de computação de grande porte são propensos a falhas de nós individuais.
- Hadoop é fundamentalmente resistente – quando um nó falha o processamento é redirecionado para os outros nós que compõe o cluster.

Escalabilidade e Desempenho

- Tratamento de dados local para cada nó em um cluster Hadoop permite armazenar, gerenciar, processar e analisar dados em escala petabyte.

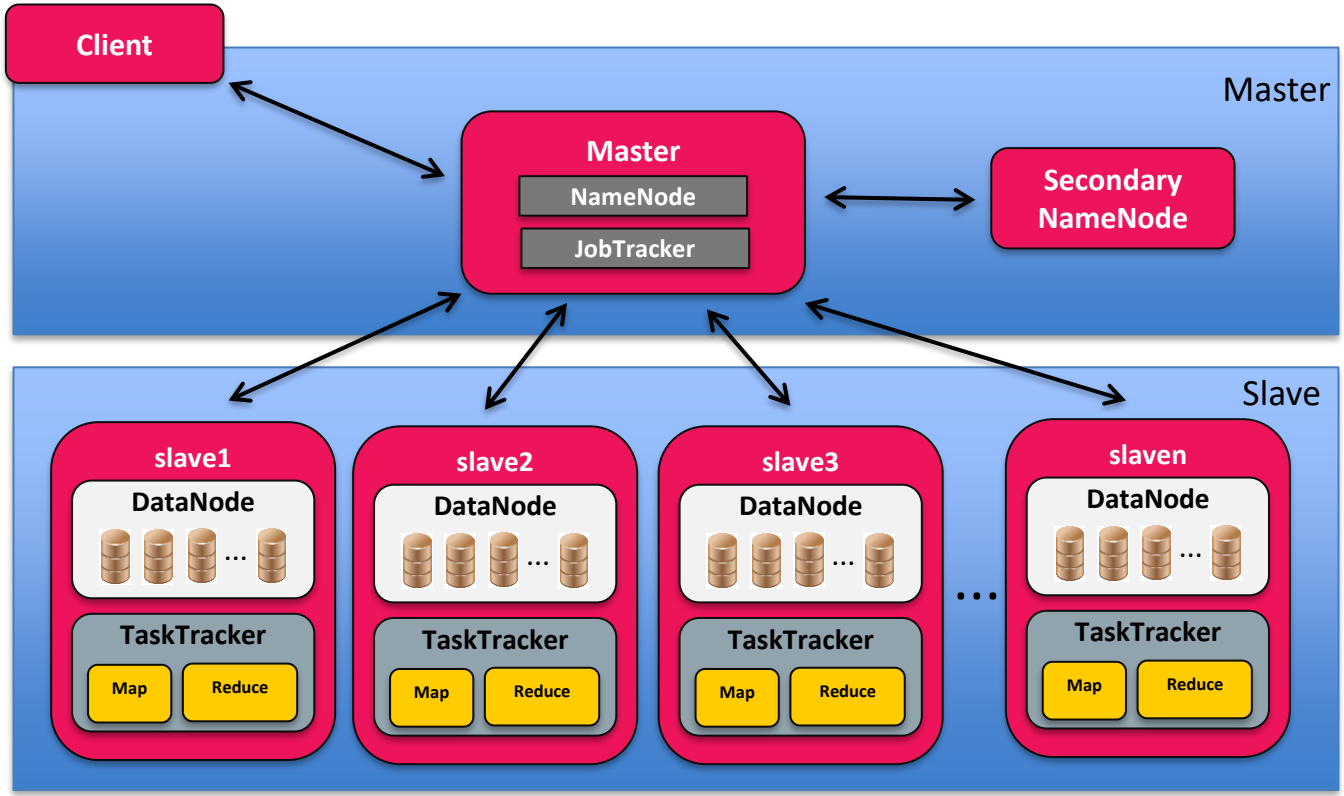
Flexibilidade

- Ao contrário de sistemas de gerenciamento de banco de dados relacionais tradicionais, não há esquemas estruturados que armazenam os dados.
- Os dados podem ser armazenados em qualquer formato, sejam estruturados, semiestruturados ou não estruturados para que, em seguida, os dados possam ser analisados.

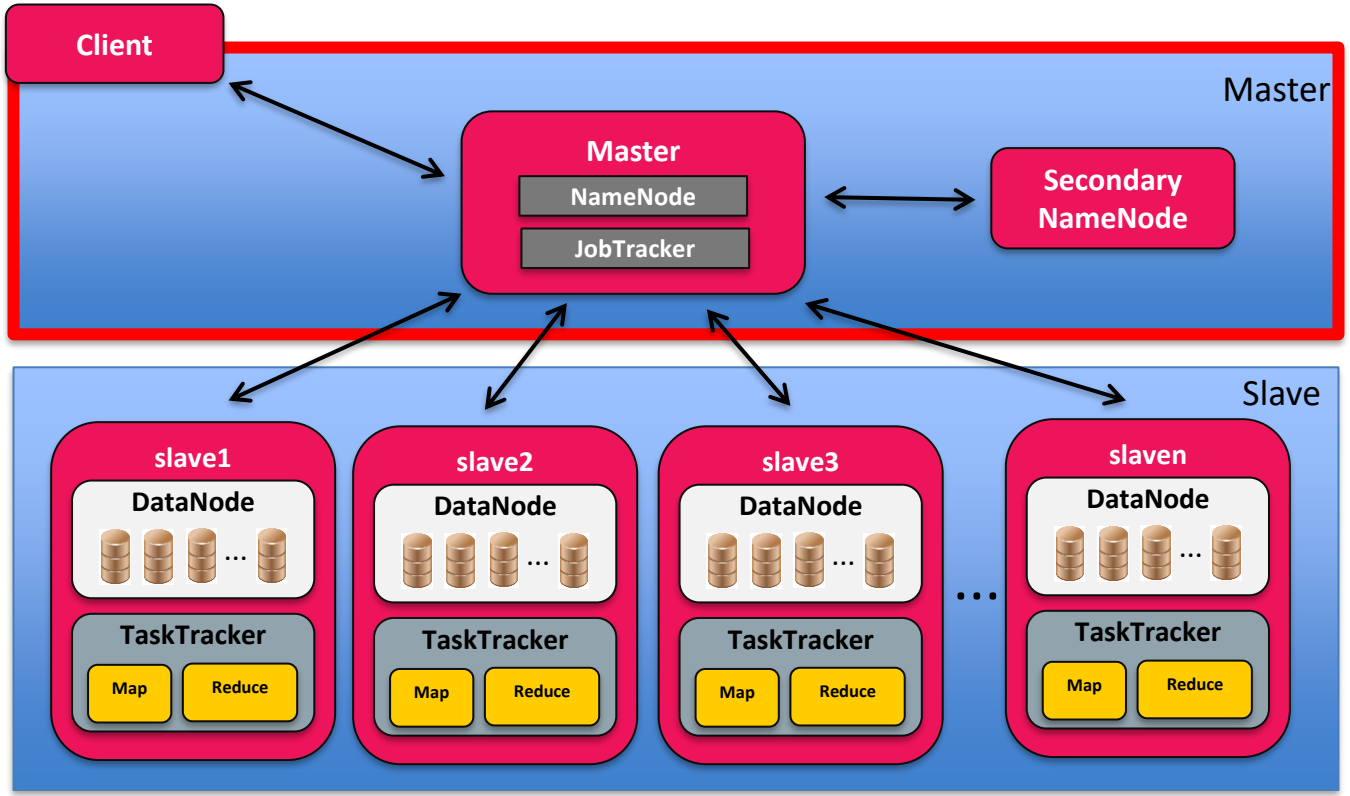
Baixo custo

- O Hadoop é open source e é executado em hardware commodity de baixo custo.

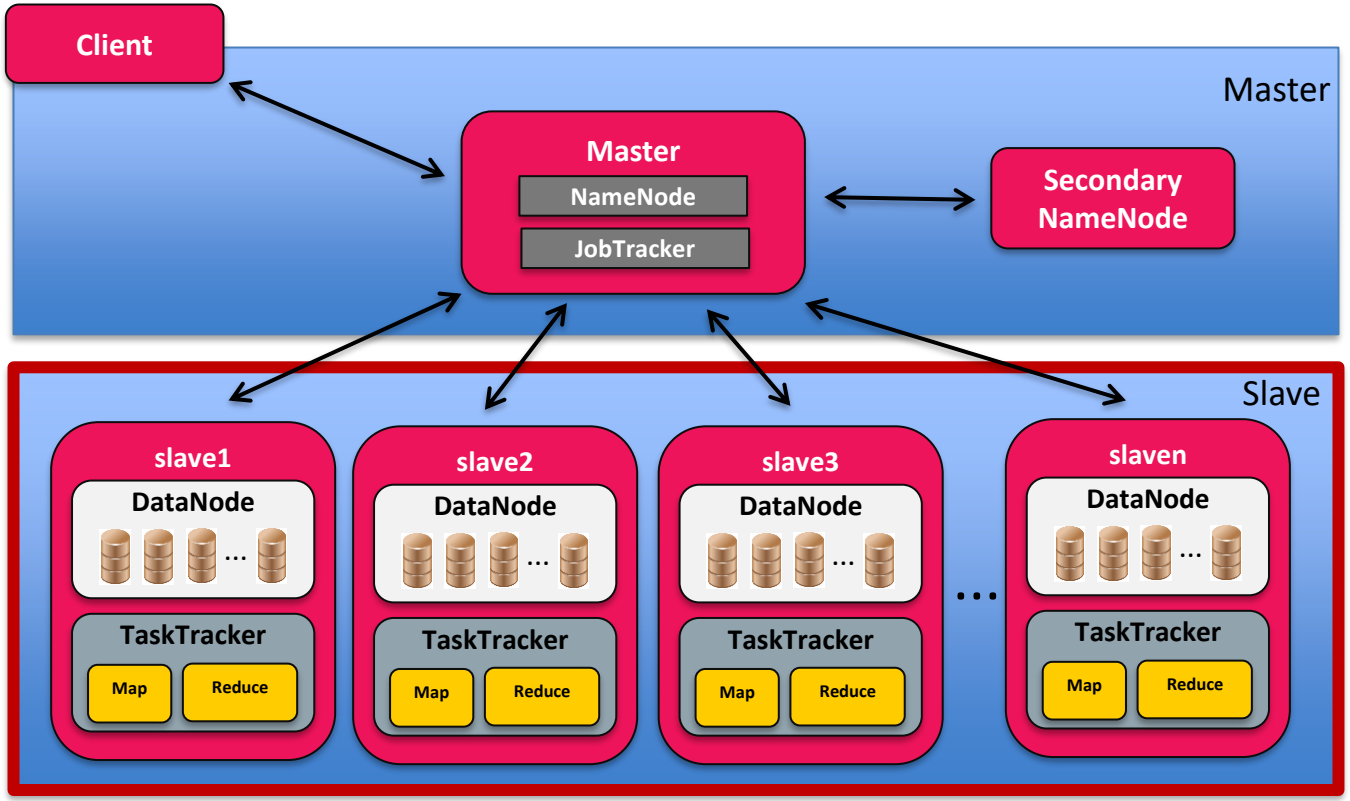
Hadoop


Client
Master
Master
NameNode
JobTracker
Secondary NameNode
Slave
slave1
DataNode
TaskTracker
Map
Reduce
slave2
DataNode
TaskTracker
Map
Reduce
slave3
DataNode
TaskTracker
Map
Reduce
slaven
DataNode
TaskTracker
Map
Reduce

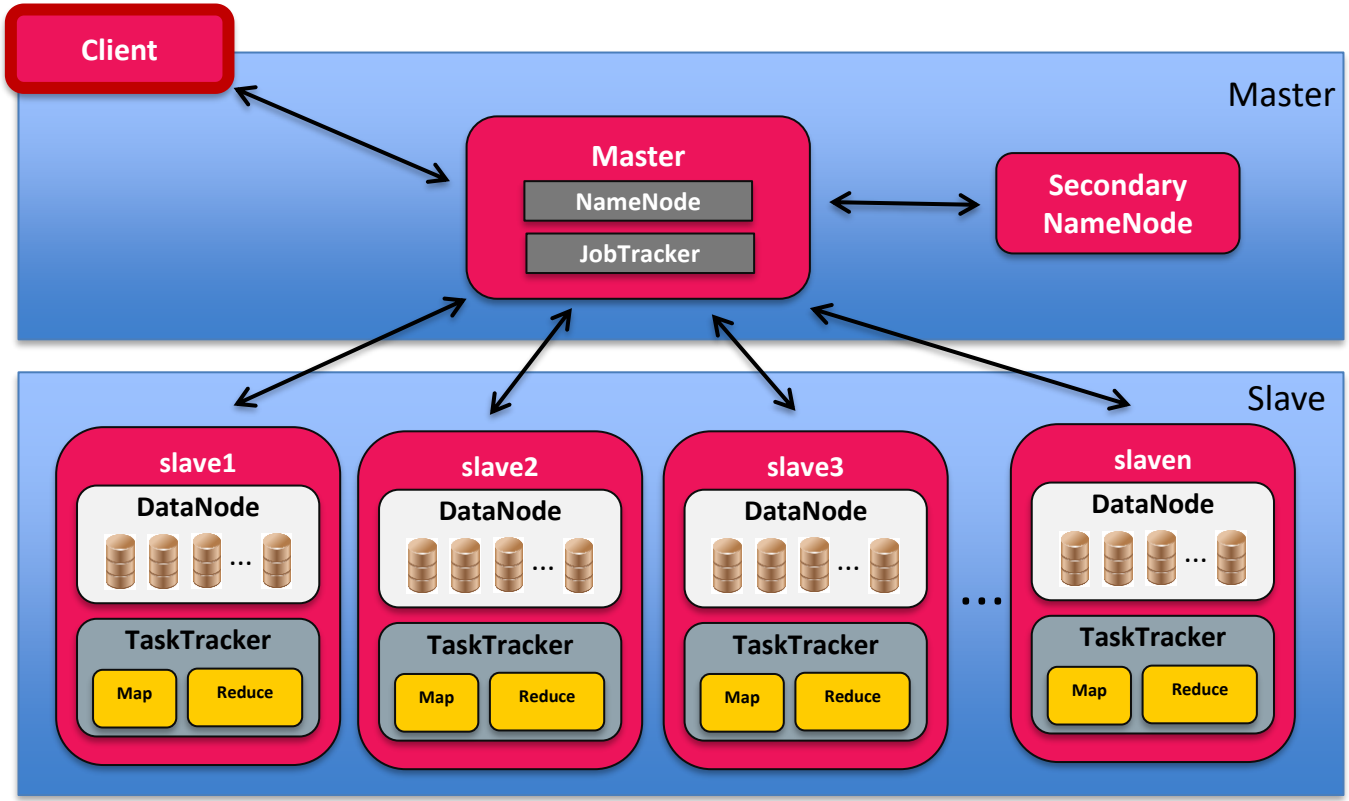
Hadoop


Client
Master
Master
NameNode
JobTracker
Secondary NameNode
Slave
slave1
DataNode
TaskTracker
Map
Reduce
slave2
DataNode
TaskTracker
Map
Reduce
slave3
DataNode
TaskTracker
Map
Reduce
slaven
DataNode
TaskTracker
Map
Reduce

Hadoop

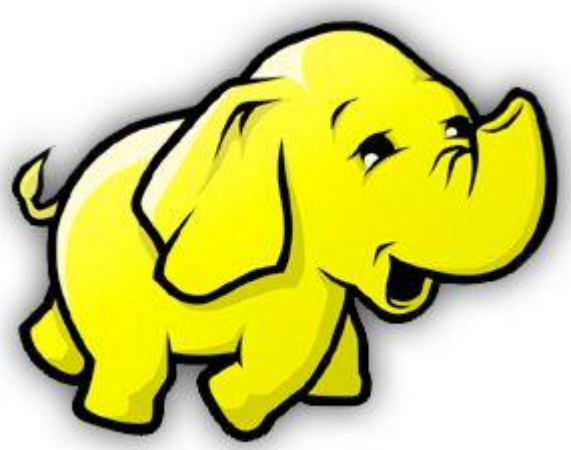

Client
Master
Master
NameNode
JobTracker
Secondary NameNode
Slave
slave1
DataNode
TaskTracker
Map
Reduce
slave2
DataNode
TaskTracker
Map
Reduce
slave3
DataNode
TaskTracker
Map
Reduce
slaven
DataNode
TaskTracker
Map
Reduce

Hadoop


Client
Master
Master
NameNode
JobTracker
Secondary NameNode
Slave
slave1
DataNode
TaskTracker
Map
Reduce
slave2
DataNode
TaskTracker
Map
Reduce
slave3
DataNode
TaskTracker
Map
Reduce
slaven
DataNode
TaskTracker
Map
Reduce

Hadoop

Modos de Execução do Hadoop



Modo Local (Standalone)

Todos os serviços Hadoop são executados em uma única JVM, no mesmo servidor

Modo Pseudo Distribuído (Pseudo-Distributed)

Serviços individuais do Hadoop são atribuídos a JVM's individuais, no mesmo servidor

Modo Totalmente Distribuído (Fully Distributed)

Serviços individuais do Hadoop são executados em JVM's individuais, mas atravésde cluster



- **Service Programming**

- O ZooKeeper é um serviço centralizado para manter informações de configuração, nomenclatura, fornecer sincronização distribuída e fornecer serviços para o grupo de máquinas do cluster.



- **NoSQL Databases**
  - **Column Data Model**

- Inspirado no Google BigTable o Apache HBASE é um banco de dados distribuído não relacional.
- Realiza operações de leitura/gravação em tempo real em tabelas muito grandes (BDDB: Big Data Base).
- É o banco de dados Hadoop. (Orientado a colunas)



- **SQL-on-Hadoop**

- Apache Hive é um software de Data Warehouse desenvolvido para trabalhar sobre o HDFS que permite realizar consultas e análise de dados.
- O Hive oferece uma interface semelhante ao SQL para consulta de dados em diferentes bancos de dados e sistemas de arquivos integrados ao Hadoop.



Apache Pig

- **Distributed Programming**

- Apache Pig é uma plataforma para analisar grandes conjuntos de dados.
- Consiste em uma linguagem de alto nível com o objetivo principal de realizar análise de dados.



- **Distributed Programming**

- Apache Spark é um framework de código fonte aberto para computação distribuída.
- Foi desenvolvido no AMPLab da Universidade da Califórnia e posteriormente repassado para a Apache Software Foundation que o mantém desde então.



APACHE SQOOP

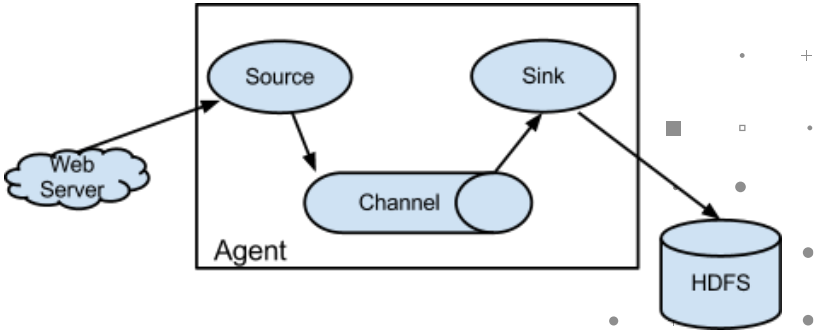
- **Data Ingestion**

- É um sistema utilizado para transferência de dados em massa entre HDFS e datastores estruturados como RDBMS.



- **Data Ingestion**

- **Flume** é um serviço distribuído, confiável e disponível para coletar, agregar e mover com eficiência grandes quantidades de dados de registro.



OBRIGADO

Copyright © 2026 | Professor (a) Alexandre Barcelos

Todos os direitos reservados. Reprodução ou divulgação total ou parcial deste documento, é expressamente proibido sem consentimento formal, por escrito, do professor/autor.


FIAP