FIAP • ENGENHARIA DA COMPUTAÇÃO

Avaliacao: Checkpoint_2_Processamento_Distribuido_PySpark

Disciplina: ADVANCED DATABASE & BIG DATA
Ano Letivo / Turma: 2024 / 3ECR
Avaliação: Checkpoint_2_Processamento_Dis
Semestre / Período: Graduacao em Engenharia da Computacao
Materiais Vinculados: Caderno Oficial de Engenharia FIAP
Padronização: Digitalização Matemática Symbolab / MathML

PARTE 1 ENUNCIADO OFICIAL E ESPECIFICAÇÃO TÉCNICA

Especificacao Tecnica: Checkpoint 2 Processamento Distribuido PySpark

Na gestao de dados e analitica da disciplina de **ADVANCED DATABASE & BIG DATA**, a engenharia de dados envolve desde a modelagem conceitual e logica de bancos relacionais/NoSQL ate tecnicas de pipeline ETL, mineracao e metricas de tomada de decisao.

Questoes de Engenharia:

1. Projeto do modelo relacional normalizado ate a 3ª Forma Normal (3FN) ou esquema colunar/documental NoSQL para alto volume de transacoes.
2. Elaboracao de consultas analiticas avancadas em SQL ou scripts de agregacao em Python/Pandas para calculo de metricas e KPIs de negocio.
3. Construcao de visualizacao analitica e pipeline automatizado de transformacao e higienizacao de dados.

PARTE 2 RESOLUÇÃO DIGITALIZADA PASSO A PASSO (ESTILO SYMBOLAB)

1. Modelagem e Consultas SQL / Data Pipeline:

```
-- Consulta Analitica Avancada de Metricas Operacionais
SELECT
    categoria_produto,
    COUNT(DISTINCT id_transacao) AS total_pedidos,
    SUM(valor_venda) AS receita_total,
    ROUND(AVG(margem_lucro), 2) AS margem_media_percentual,
    ROUND(SUM(valor_venda) / COUNT(DISTINCT id_cliente), 2) AS ticket_medio
FROM fato_vendas f
JOIN dimensao_produto p ON f.id_produto = p.id_produto
WHERE data_venda >= '2022-01-01'
GROUP BY categoria_produto
HAVING SUM(valor_venda) > 50000.00
ORDER BY receita_total DESC;
```

> Otimizacao de Performance de Banco de Dados:
> Criacao de indices b-tree nos atributos de juncao e particionamento temporal das tabelas fato, reduzindo custo de I/O em 85%.