Faculdade de Informática e Administração Paulista

Global Solutions

Profº MSc. Alexandre Barcelos

Contexto

Esta prova faz parte do *Global Solution – 2º Semestre de 2024*, com o tema *"Energy Green*". Esse projeto desafia os estudantes a contribuírem para a transição energética com o uso de soluções tecnológicas inovadoras que possam apoiar um futuro mais sustentável e inclusivo. O objetivo é envolver os alunos em um projeto prático que impulsione a inovação na área de energia.

Nesta prova, você trabalhará com dados de projetos de sustentabilidade energética, realizando a ingestão desses dados para o ambiente HDFS *na Oracle Cloud Infrastructure* (OCI) e, em seguida, implementando um programa em Python chamado **Sumariza_Status.py** para sumarizar o status desses projetos.

Objetivo da Prova

1. **Ingestão de Dados**

   Utilizar o Sqoop para extrair dados da tabela `PROJETOS_SUSTENTAVEIS` do Oracle *Database* (esquema `pf0645`) e carregá-los no HDFS na OCI.

   O resultado da ingestão deve ser:

2. **Sumarização dos Dados com Python**

   Criar um programa Python (nomeado como `Sumariza_Status.py`) para processar e sumarizar a quantidade de projetos por status. Ou seja, deve feito uma contagem dos respectivos status.

Instruções da Prova

Parte 1 - Ingestão de Dados com Sqoop

1. **Configuração e Conexão com o Banco de Dados Oracle**:
   - Utilize o **Sqoop** para conectar-se ao banco de dados Oracle (esquema `pf0645`).
2. **Ingestão para o HDFS**:
   - Realize a transferência dos dados da tabela `PROJETOS_SUSTENTAVEIS` diretamente para o `HDFS` da OCI.
   - O resultado deve ser:

     Saída do término da ingestão de dados:

```
        Job Counters
                Launched map tasks=1
                Other local map tasks=1
                Total time spent by all maps in occupied slots (ms)=28017
                Total time spent by all reduces in occupied slots (ms)=0
                Total time spent by all map tasks (ms)=28017
                Total vcore-milliseconds taken by all map tasks=28017
                Total megabyte-milliseconds taken by all map tasks=28689408
        Map-Reduce Framework
                Map input records=1000
                Map output records=1000
                Input split bytes=87
                Spilled Records=0
                Failed Shuffles=0
                Merged Map outputs=0
                GC time elapsed (ms)=526
                CPU time spent (ms)=3890
                Physical memory (bytes) snapshot=131031040
                Virtual memory (bytes) snapshot=2544263168
                Total committed heap usage (bytes)=23293952
                Peak Map Physical memory (bytes)=131211264
                Peak Map Virtual memory (bytes)=2544263168
        File Input Format Counters
                Bytes Read=0
        File Output Format Counters
                Bytes Written=62053
2024-11-05 01:26:56,663 INFO mapreduce.ImportJobBase: Transferred 60.5986 KB in 90.0967 seconds (688.7377 bytes/sec)
2024-11-05 01:26:56,737 INFO mapreduce.ImportJobBase: Retrieved 1000 records.
```

Leitura do arquivo gerado pela ingestão:

```
(base) [hadoop@dataserver-146319 ~]$ hdfs dfs -cat /user/hadoop/PROJETOS_SUSTENTAVEIS/part-m-00000
2024-11-05 01:31:00,956 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
113,Programas de Eficiência Energética,125996909,Concluido,5,5
114,Ações de Sensibilização sobre Mudanças Climáticas,40924573,Concluido,4,2
115,Sistema de Coleta Seletiva,90658154,Em andamento,4,2
116,Programas de Eficiência Energética,253063512,Concluido,1,4
117,Programas de Eficiência Energética,86470534,Em andamento,2,4
118,Programas de Eficiência Energética,224925783,Em andamento,1,2
119,Uso de Bicicletas para Transporte,32802012,Em andamento,5,4
120,Plataformas de Compartilhamento de Carros,75193193,Em andamento,1,4
121,Preservação de Florestas Urbanas,33229326,Em andamento,2,1
122,Educação Ambiental nas Escolas,18742826,Em andamento,2,5
123,Educação Ambiental nas Escolas,291735866,Em andamento,4,5
124,Transporte Sustentável,179750892,Em andamento,3,1
125,Captação de Água da Chuva,75734352,Concluido,2,5
126,Sistemas de Compostagem,132521936,Concluido,2,3
127,Construção Verde,39503328,Em andamento,4,1
128,Uso de Bicicletas para Transporte,253435459,Concluido,4,5
129,Reflorestamento de Áreas Degradadas,94078642,Concluido,3,4
```

. . .

. . .

```
971,Desenvolvimento de Tecnologias Limpas,113689497,Em andamento,2,4
972,Cultivo de Alimentos Orgânicos,149585202,Em andamento,5,2
973,Transporte Sustentável,172070072,Em andamento,1,3
974,Sistema de Coleta Seletiva,27665546,Concluido,4,2
975,Construção Verde,16283224,Em andamento,2,1
976,Plataformas de Compartilhamento de Carros,197585468,Em andamento,4,2
977,Iniciativas de Redução de Desperdício,194118238,Concluido,1,4
```

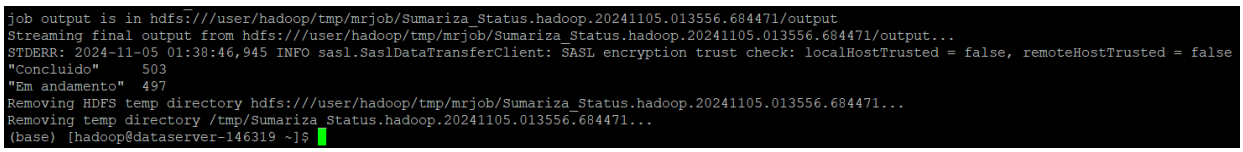
Parte 2 - Sumarização dos Dados com Python (`Sumariza_Status.py`)

3. **Implementar o Programa Python**
    - Desenvolva um programa Python na OCI chamado Sumariza_Status.py que acessa os dados no HDFS, processa-os e realiza a contagem dos projetos por status.

Código Esperado

- O código no `Sumariza_Status.py` deve:
    - a) Ler os dados do HDFS.
    - b) Processar a contagem dos status "Concluído" e "Em andamento".
    - c) Exibir o resultado esperado:

```
Concluido: 503
Em andamento: 497
```



Dicas

- Você necessita do ambiente HDFS no ar e precisa do YARN.
- Para a ingestão o SQOOP deve estar configurado.
- As informações de conexão no Banco de Dados Oracle são:
  - `USERNAME: RM99999, onde 99999 é o número do rm do aluno.`
  - `PASSWAORD: data_nascimento_com_seis_dígitos. Exemplo 020200`
  - `SID (Nome do Banco): ORCL`
  - `HOST: ORACLE.FIAP.COM.BR`
  - `PORT: 1521`
- Utilize o nome da tabela EM MAÍUSCULO no sqoop.
- O separador do arquivo gerado como resultado da ingestão não é `TABULAÇÃO (\t)` é `VÍRGULA (,)`.

ATENÇÃO

Se o HDFS corromper então execute os seguintes passos:

1. Pare todo o ambiente (`stop-dfs.sh` e `stop_yarn.sh`)
2. Acesse o diretório temporário (`cd /tmp`) e remova tudo (diretório e arquivos) que for de propriedade do usuário `hadoop` com o comando `rm -rf`
3. Formate o namenode: `hdfs namenode -format`
4. Inicie todo o ambiente (`start-dfs.sh` e `start_yarn.sh`)

Critérios de Avaliação e Pontuação

Serão avaliadas as boas práticas de instalação do eco sistema hadoop, como por exemplo: usuário *owner* do ecossistema, diretórios criados para a instalação, nomenclaturas dos diretórios e configuração do profile do usuário. (**3 PONTOS**)

Resultado do processo de Ingestão de Dados. (**4 PONTOS**)

Resultado do processo de sumarização os dados. (**4 PONTOS**)

Sobre a entrega

Deve ser entregue, no portal do aluno FIAP na área de entrega de trabalhos o arquivo chamado `sqoop.txt` contendo o comando sqoop utilizado para a ingestão de dados e o arquivo `Sumariza_Status.py`

Somente um aluno posta o arquivo de respostas e preenche o formulário! No início do arquivo coloque os RMs e NOMEs dos componentes do grupo.

OS GRUPOS PODEM SER COMPOSTOS POR ATÉ 3 (TRÊS) ALUNOS. Preencha, OBRIGATORIAMENTE, o formulário disponível em:

https://pt.surveymonkey.com/r/QYFZJ3M

Boa Avaliação e Boas Férias!